

HỘI THI AI CHALLENGE THÀNH PHỐ HỒ CHÍ MINH 2026

VÒNG SƠ TUYỂN

BÁO CÁO KỸ THUẬT TÓM TẮT

HỆ THỐNG TRUY XUẤT THÔNG TIN ĐA PHƯƠNG THỨC TỪ DỮ LIỆU VIDEO

Đội thi: TongFC

Thành viên:

- Bùi Thị Bích Loan
- Huỳnh Thanh Phúc
- Lê Trần Nguyên Ngọc
- Nguyễn Diệp Thân

Đơn vị: Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Thành phố Hồ Chí Minh

Thành phố Hồ Chí Minh, ngày 12 tháng 09 năm 2026

Mục lục

1. Tổng quan hệ thống	3
1.1. Môi trường và Các Công cụ AI	3
2. Giải pháp, Thuật toán và Mô hình AI	3
2.1. Xử lý Keyframe và Deduplication	3
2.2. Nhận dạng Giọng nói (ASR)	3
2.3. Nhận dạng Văn bản trong Ảnh (OCR)	4
2.4. Phát hiện Vật thể (Object Detection)	4
2.5. Chỉ mục Không gian Visual (CLIP)	4
2.6. Chiến lược kết hợp Đa phương thức (Multi-modal Fusion)	4
3. Phân tích Tình huống Truy vấn Tiêu biểu	4
3.1. Tình huống 1: Concept thị giác hiếm (KIS - Xe lội nước kiểu ô tô cổ)	4
3.2. Tình huống 2: Phối hợp OCR và Visual (KIS - Slide bài giảng tiếng Anh)	4
3.3. Tình huống 3: Trích xuất số lượng và đơn vị (QA - Lượng nước tương)	4
3.4. Tình huống 4: Suy luận logic nhiều bước (QA - Số nhóm X)	5
3.5. Tình huống 5: Căn chỉnh chuỗi sự kiện (TRAKE - Bốn mốc làm món tôm)	5
4. Giao diện Hệ thống và Công tác Vận hành	5
4.1. Kiến trúc Giao diện Người dùng (UI)	5
4.2. Kinh nghiệm Vận hành	6

1. Tổng quan hệ thống

Hệ thống của đội được phát triển nhằm mục đích giải quyết bài toán truy xuất thông tin đa phương thức từ tập dữ liệu video quy mô lớn trong khuôn khổ Hội thi AI Challenge Thành phố Hồ Chí Minh 2026.

Với 873 video (từ L21 đến L30), hệ thống đã trích xuất thành công 196.590 keyframe và xây dựng một pipeline end-to-end hoàn chỉnh bao gồm 4 giai đoạn chính:

1. Trích xuất Keyframe: Xử lý dữ liệu thô (ZIP), trích xuất hình ảnh, loại bỏ trùng lặp (deduplication) và chuẩn hóa.
2. Trích xuất Đặc trưng Đa phương thức: Thực hiện nhận dạng giọng nói (ASR), nhận dạng văn bản (OCR) và phát hiện vật thể (Object Detection).
3. Lập Chỉ mục (Indexing): Xây dựng các cấu trúc tìm kiếm tối ưu (FAISS cho vector, SQLite FTS cho văn bản).
4. Hệ thống Truy vấn (Search Engine): Giao diện web cho phép tìm kiếm và kết hợp đa phương thức (Multi-modal Fusion).

Điểm nổi bật của hệ thống là khả năng xử lý khối lượng dữ liệu khổng lồ trong điều kiện tài nguyên hạn chế (bộ nhớ trong 35GB) nhờ thiết kế luồng xử lý “Tải -> Giải nén -> Xử lý -> Xóa” hiệu quả, kết hợp cơ chế lưu điểm kiểm tra (checkpoint) để có thể tiếp tục tự động sau khi bị gián đoạn.

1.1. Môi trường và Các Công cụ AI

Để xây dựng và vận hành toàn bộ hệ thống, đội đã sử dụng phối hợp nhiều tài nguyên và công cụ mã nguồn mở:

- Môi trường tính toán: Hệ thống notebook của Kaggle được sử dụng để tận dụng phần cứng GPU miễn phí nhằm xử lý khối lượng lớn video, trích xuất đặc trưng và xây dựng chỉ mục.
- Mô hình Trí tuệ Nhân tạo (AI Models): Sử dụng mô hình CLIP (ViT-B-32-quickgelu) cho đối sánh hình ảnh - văn bản; Whisper-medium của OpenAI cho nhận dạng giọng nói (ASR); EasyOCR cho nhận dạng chữ trên màn hình; Faster R-CNN cho phát hiện vật thể. Đặc biệt, đội ứng dụng mô hình ngôn ngữ lớn đa phương thức Qwen3-VL (2B và 8B) để hậu xử lý tự động.
- Lưu trữ và Cơ sở dữ liệu: Sử dụng FAISS để tìm kiếm vector tốc độ cao và SQLite FTS5 để tìm kiếm văn bản toàn văn (Full-Text Search).
- Phát triển phần mềm: Giao diện người dùng (UI) được xây dựng bằng React/Vite, kết nối với server FastAPI (Python).

2. Giải pháp, Thuật toán và Mô hình AI

Hệ thống tích hợp nhiều mô hình Trí tuệ Nhân tạo hiện đại nhất để bóc tách thông tin từ đa chiều (hình ảnh, âm thanh, văn bản).

2.1. Xử lý Keyframe và Deduplication

- Sử dụng OpenCV để trích xuất với tần suất 1 frame/giây.
- Nhằm tối ưu hóa số lượng ảnh cần tìm kiếm, hệ thống tự động loại bỏ các frame trùng lặp bằng cách tính toán 3D Color Histogram (không gian BGR, 8x8x8 bins) và sử dụng hàm tương quan (correlation). Các frame có độ tương đồng lớn hơn hoặc bằng 0.95 sẽ bị loại bỏ, giúp giảm nhiễu.

2.2. Nhận dạng Giọng nói (ASR)

- Mô hình chính: OpenAI Whisper-medium. Phân mảnh âm thanh thành các đoạn (segments) có dấu thời gian (start, end).
- Hậu xử lý (LMM): Sử dụng mô hình Qwen3-VL-8B-Instruct. Lời thoại từ video tiếng Việt thường bị nhận dạng sai dấu hoặc sai từ do nhiễu âm thanh. Qwen3-VL được tinh chỉnh qua prompt để sửa lỗi chính tả, chuẩn hóa văn bản mà không tự ý thêm bớt nội dung.
- Index: SQLite FTS5 (Full-text search), dung lượng 7.62MB, 11.061 segments.

2.3. Nhận dạng Văn bản trong Ảnh (OCR)

- Mô hình chính: EasyOCR hỗ trợ song ngữ (vi + en). Trích xuất các hộp văn bản (bounding boxes) và sắp xếp theo thứ tự đọc (từ trên xuống, trái sang phải).
- Hậu xử lý (LMM): Sử dụng Qwen3-VL-2B-Instruct. Sửa lỗi nhận diện sai ký tự đặc thù của tiếng Việt và ngắt câu hợp lý.
- Index: SQLite FTS5, dung lượng 338.87MB.

2.4. Phát hiện Vật thể (Object Detection)

- Mô hình: Faster R-CNN InceptionResNetV2 (TensorFlow Hub, huấn luyện trên OpenImages V4).
- Tính năng: Phát hiện hơn 600 lớp vật thể. Hệ thống sử dụng thêm bộ từ điển (alias) để ánh xạ các nhãn tiếng Anh sang tiếng Việt, hỗ trợ truy vấn bằng cả hai ngôn ngữ.
- Index: SQLite Database, ghi nhận 905.974 detections thuộc 503 classes.

2.5. Chỉ mục Không gian Visual (CLIP)

- Mô hình: CLIP ViT-B-32-quickgelu (từ thư viện open_clip_torch).
- Chỉ mục: Chuyển đổi toàn bộ 196.590 keyframe thành vector 512 chiều. Xây dựng chỉ mục FAISS (IndexFlatIP) để thực hiện tìm kiếm ảnh bằng văn bản (Text-to-Image) với độ trễ tính bằng mili-giây.

2.6. Chiến lược kết hợp Đa phương thức (Multi-modal Fusion)

Hệ thống cho phép thực hiện song song các loại truy vấn: Semantic (CLIP), Lời thoại (ASR), Chữ viết trên màn hình (OCR) và Vật thể (Object). Sau đó, kết quả được hợp nhất bằng thuật toán Reciprocal Rank Fusion (RRF) có trọng số và áp dụng cơ chế score gating để loại bỏ các nhiễu từ tín hiệu yếu.

3. Phân tích Tình huống Truy vấn Tiêu biểu

Bộ câu hỏi P2 gồm 36 câu: 26 KIS, 8 Q&A và 2 TRAKE. Theo yêu cầu kỹ thuật, bộ đề gồm 15 câu KIS thị giác–đối tượng, 6 câu KIS có diễn tiến thời gian, 5 câu KIS có chữ hoặc sơ đồ, 6 câu Q&A dựa trên OCR/ASR, 1 câu đếm thị giác, 1 câu suy luận logic và 2 câu căn chỉnh chuỗi sự kiện.

Dưới đây là 5 tình huống tiêu biểu được chọn lọc nhằm bao quát các năng lực và giới hạn hiện tại của hệ thống:

3.1. Tình huống 1: Concept thị giác hiếm (KIS - Xe lội nước kiểu ô tô cổ)

- Mã câu hỏi: p2-10-kis
- Đặc điểm & Tiếp cận: Cần tìm một hình ảnh rất đặc trưng (“xe lội nước”).
- Kết quả & Bài học: Với concept có hình dạng thị giác đặc trưng như xe lội nước kiểu ô tô cổ, CLIP là nhánh truy xuất phù hợp nhất; Object Index đóng vai trò bổ trợ do tập nhãn chỉ biểu diễn các lớp vật thể tổng quát.

3.2. Tình huống 2: Phối hợp OCR và Visual (KIS - Slide bài giảng tiếng Anh)

- Mã câu hỏi: p2-4-kis
- Đặc điểm & Tiếp cận: Truy vấn tìm hình ảnh chứa các ví dụ ngữ pháp tiếng Anh. Nếu chỉ dùng CLIP tìm “giáo viên nữ”, hệ thống sẽ bị nhiễu do có nhiều frame tương tự. Visual định vị bối cảnh lớp học, OCR đọc các câu ví dụ và công thức trên màn hình, còn ASR bổ trợ bằng nội dung giảng giải được phát âm trong video.
- Bài học: Sự kết hợp đa phương thức này được sử dụng để thu hẹp không gian ứng viên. Text index (OCR) là tín hiệu “vân tay” xuất sắc cho các truy vấn chứa văn bản rõ ràng.

3.3. Tình huống 3: Trích xuất số lượng và đơn vị (QA - Lượng nước tương)

- Mã câu hỏi: p2-24-qa
- Đặc điểm & Tiếp cận: Cần tìm số lượng nước tương được sử dụng. Hệ thống định vị scene, chạy OCR/ASR, và trích xuất ra các con số. Tuy nhiên, các ứng viên trả về bao gồm “200g”, “3l”, “3muỗng” phân tán ở nhiều video khác nhau.

- Kết quả & Bài học: Hệ thống đã nhận dạng được chữ và số, nhưng bộc lộ hạn chế trong việc “gắn số đo với đúng thực thể” (nước tương). Cần cải thiện việc liên kết (grounding) thông tin số lượng với ngữ cảnh thay vì chỉ bóc tách con số nổi bật nhất.

3.4. Tình huống 4: Suy luận logic nhiều bước (QA - Số nhóm X)


- Mã câu hỏi: p2-35-qa
- Đặc điểm & Tiếp cận: Đáp án không xuất hiện trực tiếp mà phải suy luận từ 4 câu trắc nghiệm trên màn hình (đều chứa chữ số 0). Cơ chế text-mode hiện tại chỉ trích xuất các chữ số thô (ví dụ: 3020, 73, 2, 0) mà chưa giải quyết được bài toán điều kiện logic.
- Bài học: Có một khoảng trống lớn giữa việc “truy xuất văn bản thuần túy” và “suy luận logic”. Cần một mô-đun LLM/VLM đủ mạnh chạy trên nhiều frame để giải quyết dạng câu hỏi này.

3.5. Tình huống 5: Căn chỉnh chuỗi sự kiện (TRAKE - Bốn mốc làm món tô)

- Mã câu hỏi: p2-21-trake
- Đặc điểm & Tiếp cận: Khác với định dạng cũ, TRAKE đặt 3 yêu cầu 4 mốc thời gian diễn ra trong cùng một video và phải tăng nghiêm ngặt về frame ($E1 < E2 < E3 < E4$). Engine TRAKE tách 4 event, tìm ứng viên, chuẩn hóa điểm và chạy thuật toán quy hoạch động (K-best DP) để tìm ra chuỗi sự kiện liên mạch nhất.
- Kết quả: Hệ thống xếp hạng cao nhất chuỗi ứng viên trong video L26_V156 với các frame 2875, 3825, 4900 và 4925. Chuỗi thỏa điều kiện cùng video và thứ tự frame tăng nghiêm ngặt; độ chính xác nội dung cần được xác nhận bằng kết quả chấm chính thức.

4. Giao diện Hệ thống và Công tác Vận hành

Hệ thống được thiết kế dưới dạng ứng dụng Web hiện đại (xây dựng bằng React/Vite) giao tiếp với backend thông qua REST API, tối ưu hóa cho thao tác tìm kiếm tốc độ cao trong giờ thi.



Hình 1: Giao diện ứng dụng tìm kiếm đa phương thức của đội

4.1. Kiến trúc Giao diện Người dùng (UI)

Giao diện được chia thành hai phần chính: Sidebar (Cột điều hướng bên trái) và Main Area (Vùng hiển thị kết quả chính).

1. Sidebar - Bảng Điều khiển Truy vấn:

- Mode Search: Hỗ trợ chuyển đổi nhanh giữa tìm kiếm văn bản (Text), tìm kiếm bằng hình ảnh (Image/Upload) và tìm kiếm chuỗi sự kiện (Temporal).

- Model Selection: Cho phép người dùng chọn mô hình xử lý (CLIP, BEiT3, BLIP2, MiniGPT-4, LLaVA).
 - Bộ lọc đa phương thức: Cung cấp ô nhập liệu (Filter Panel) để lọc riêng theo các từ khóa xuất hiện trong OCR (văn bản trên màn hình) hoặc ASR (lời thoại).
 - Tùy chỉnh hệ thống: Cho phép điều chỉnh số lượng kết quả trả về (Top K) và thay đổi API Base URL linh hoạt.
2. Main Area - Lưới Kết quả (Result Grid):
- Hiển thị tổng số kết quả tìm được và thời gian truy vấn thực tế (chỉ vài chục mili-giây).
 - Grid Density: Cho phép thay đổi mật độ hiển thị (từ 2 đến 7 cột) để dễ dàng lướt qua hàng trăm keyframe cùng lúc.
 - Mỗi thẻ (Keyframe Card) hiển thị ảnh thumbnail và điểm số tương đồng (Score).
3. Detail Modal - Trình xem chi tiết:
- Khi click vào một keyframe, hệ thống sẽ mở pop-up phóng to hình ảnh cùng các nút điều hướng (Next/Previous).
 - Hiển thị đầy đủ thông số: video_id, frame_index, score, và timestamp (được định dạng chuẩn mm:ss).
 - Trích xuất thông tin: Nếu frame có văn bản, hộp thoại sẽ tự động hiển thị box text OCR (chữ trên hình) và ASR (lời thuyết minh).
 - Công cụ nộp bài: Cung cấp nút **“Copy video_id, frame”** sao chép nhanh chuỗi định dạng nộp kết quả chuẩn (ví dụ: L26_V156, 4925), và nút **“Find similar”** để tự động chuyển sang chế độ tìm kiếm bằng ảnh tương tự.

4.2. Kinh nghiệm Vận hành

Qua các đợt thi, đội nhận thấy việc tách biệt bộ lọc OCR/ASR ngay trên giao diện giúp các thành viên chia nhỏ công việc rất hiệu quả. Một người có thể tìm kiếm theo ngữ nghĩa hình ảnh thông thường, trong khi một người khác khai thác sâu các khung hình có lời thoại cụ thể. Các nút Copy nhanh (Clipboard) và Find Similar tiết kiệm được rất nhiều thời gian thao tác tay, giúp đội tăng tốc độ chốt đáp án đối với các câu hỏi khó.